

# Diseño y Validación de Algoritmos de Detección de Objetos para la Capa de Percepción del Sistema Avanzado de Asistencia para Conducción (ADAS) en Vehículos Autónomos

---

CRISTOFHER SOLÍS JIMÉNEZ


# Problema detectado

- NICR trabaja en la validación de sistemas de transporte (convencional y autónomo).
- Estos sistemas ADAS se utilizan en Unidades de Control Electrónicas (ECU)
- Estas ECU son de uso limitado ya que les pertenecen a las empresas clientes.
- Se necesita un entorno en el cual se realicen pruebas de concepto para proyectos tanto internos como externos



# Objetivo General

Diseñar un sistema de detección de objetos para la capa de percepción en un sistema de frenado automático de emergencia.



Entregable Final:

- Algoritmo completo de detección, rastreo y comunicación debidamente diseñado y validado

# Objetivos Específicos

---

## 1. Investigar sobre los distintos métodos, en que se desarrolla la detección de objetos.

Entregable: Estudio realizado sobre las múltiples arquitecturas y estrategias de desarrollo de aplicaciones de detección de objetos en tiempo real.

## 2. Diseñar un sistema de visión artificial para un sistema ADAS.

Entregables: Guía de diseño para el programa de detección de objetos.

Indicador: El prototipo diseñado debe ser capaz de detectar objetos a través de video a 20 fotogramas por segundo

## 3. Diseñar una aplicación en software para los 3 mejores diseños obtenidos.

Entregable: Guía de diseño de los prototipos de software.

Indicador: Los algoritmos deben cumplir con una precisión al detectar objetos de al menos 90%

# Objetivos Específicos

---

4. Integrar el sistema de visión junto con el sistema de control del simulador del sistema ADAS.

Indicador: El sistema debe tener una tasa de error en la comunicación entre 0 y 5%

5. Verificar el funcionamiento del sistema completo.

Indicador: Sistema completo funcional el cual tenga una capacidad de clasificación de al menos **90%**.

Entregable: Documento con los resultados obtenidos de la verificación del sistema de visión.

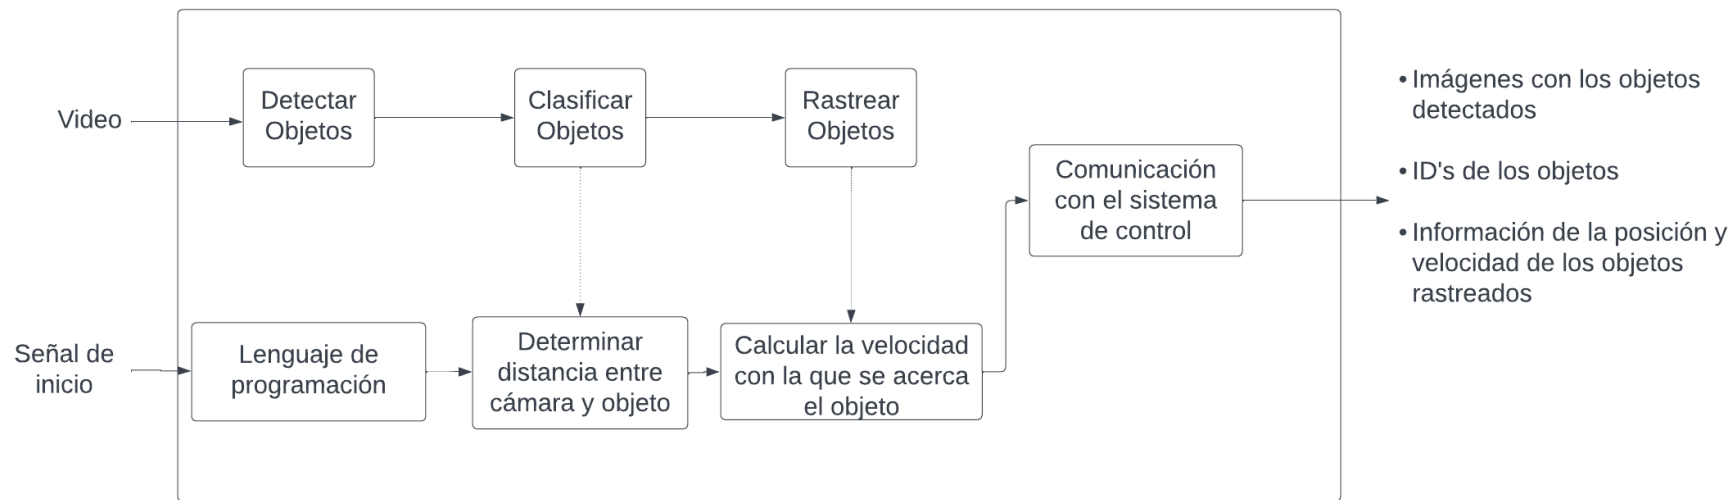
# Metodología de trabajo

---



# División en subproblemas

---



# Métricas definidas

Número de métrica	Número de necesidad	Métrica	Importancia	Unidades	Valor marginal	Valor Ideal
1	1, 4	Precisión al detectar objetos en ambientes sencillos [1]	5	Porcentaje	> 80	> 90
2	1,4	Precisión al detectar objetos en ambientes medianamente complejos [1]	5	Porcentaje	>70	>80
3	1,4	Precisión al detectar objetos en ambientes complejos [1]	4	Porcentaje	>30	>40
4	2	Tiempo de procesamiento de imágenes	5	ms	> 50	> 25
5	3	Clases distintas de objetos en que se puede clasificar	5	Cantidad	2	> 3
6	4	Precisión del rastreo	5	Porcentaje	> 70	> 90
7	5	Tiempo de procesamiento y envío de información a la capa de control	5	ms	> 30	< 30
8	6	Potencia utilizada por el SD	4	W	< 200	< 50
9	9	Precisión del sistema completo [1]	4	Porcentaje	90	100
11	11	Memoria RAM necesaria	3	GB	> 20	< 8



# Referencia comercial para filtrar conceptos

**Resultados de experimentos del modelo comercial YOLOv5-ADAS en el conjunto de datos “KITTI” [2]**

Referencia	Imagen Sencilla (%)	Imagen Moderada (%)	Imagen Compleja (%)	Promedio (%)	Tiempo de procesamiento promedio (s)
Automóvil	95.92	93.31	85.44	91.45	0.019
Ciclista	82.29	66.33	61.23	69.4	0.025
Peatón	71.49	54.07	47.82	56.96	0.050

# Calificación y filtrado de conceptos

Criterios de selección	Conceptos						
	Yolov5 - ADAS	A	B	C	D	E	F
Precisión en imágenes sencillas	0	0	+	+	+	-	+
Precisión en imágenes moderadamente complejas	0	+	+	+	0	-	+
Precisión en imágenes considerablemente complejas	0	-	0	0	-	-	0
Tiempo de detección promedio	0	+	-	+	-	+	-
Precisión del rastreo	0	+	+	-	+	-	+
Precisión en la distancia estimada entre SD y objeto detectado	0	+	+	-	-	-	+
Efectividad de comunicación	0	+	+	+	0	0	+
Suma +	0	5	5	4	2	1	5
Suma 0	0	1	1	1	2	1	1
Suma -	0	1	1	2	3	5	1
Evaluación neta	0	4	4	2	-1	-4	4
Lugar	Ref	1	1	2	3	4	1
¿Continuar?		Sí	Sí	No	No	No	Sí



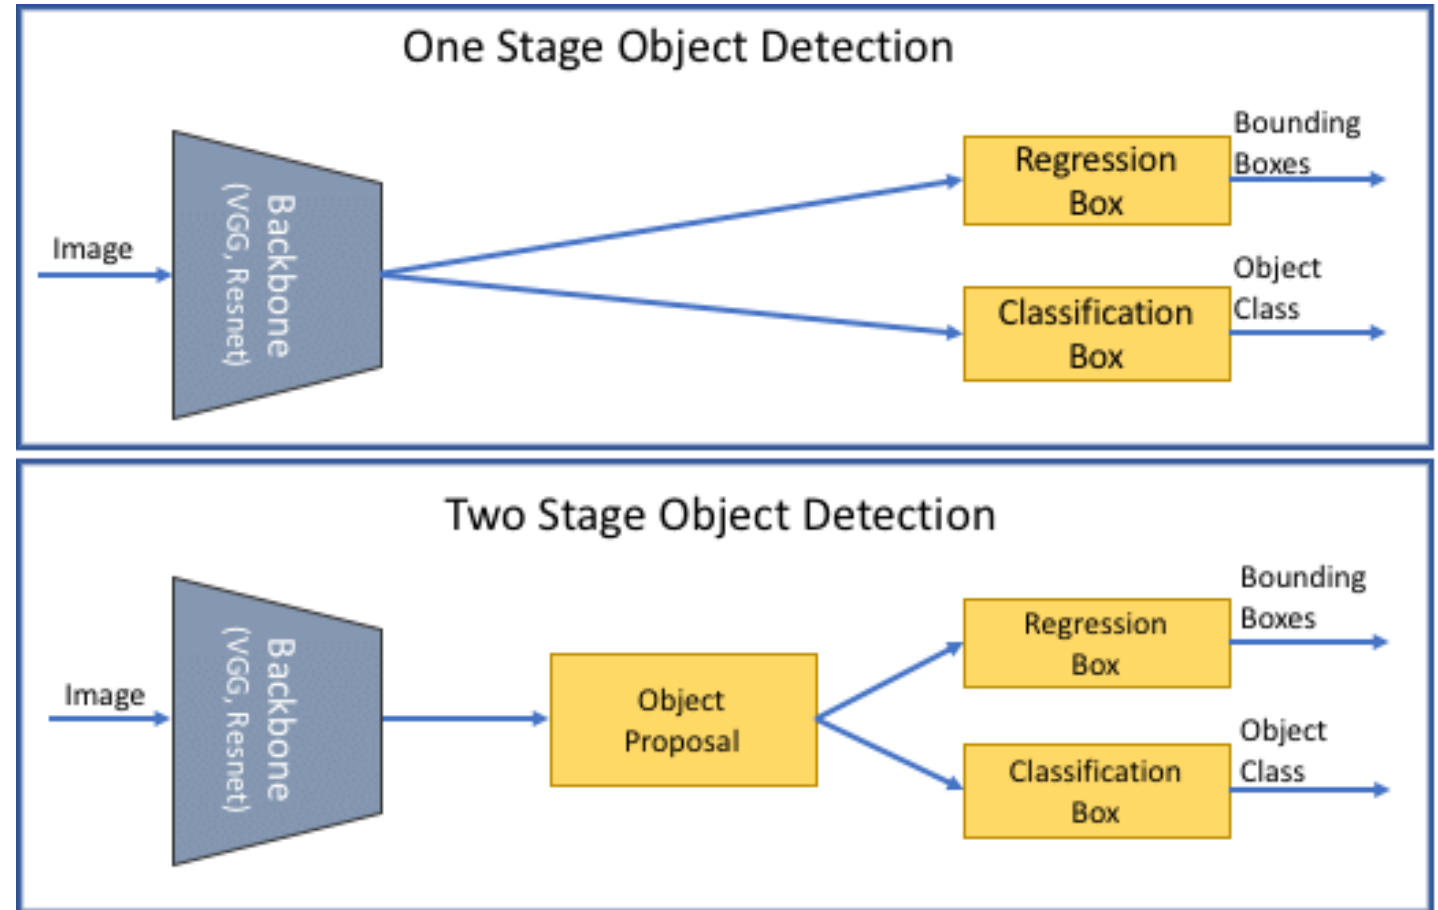
# Propuesta de Diseño

---

# Propuesta de diseño: Seleccionar arquitecturas

Yolov8 y SSD-NAS lideran las  
arquitecturas de una etapa

F-RCNN lidera la arquitectura de dos  
etapas



# Propuesta de Diseño: Entrenamiento del modelo

3 Arquitecturas distintas. Un solo dataset: KITTI

Solución 1: Yolov8

Épocas	Tasa de aprendizaje	Tamaño del lote de entrenamiento	Modelo base
64	0.001	4	Yolov8-n
128	0.01	8	Yolov8-s
256	0.1	16	Yolov8-l

Solución 2: Detectron2


Épocas	Tasa de aprendizaje	Tamaño del lote de entrenamiento	Modelo base
512	0.001	4	R-50-C4
1024	0.01	8	HRNetV2p-W48
2048	0.1	16	fasterrcnn_x_101

Solución 3: SSD-NAS

Épocas	Tasa de aprendizaje	Tamaño del lote de entrenamiento	Modelo base
32	0.001	4	SSD NASNet
64	0.01	8	SSD ResNet
128	0.1	16	SSD512

# Propuesta de Diseño: Diseño de rastreo de objetos

---



# Propuesta de Diseño: Generación de entorno virtual para validación

---

Se generaron 3 escenarios virtuales distintos en la aplicación NI Monodrive para poner a prueba el comportamiento del algoritmo, estos se encuentran en la sección “Escenarios\_de\_Simulación”



# Propuesta de Diseño: Optimizaciones




Contraste



Ruido

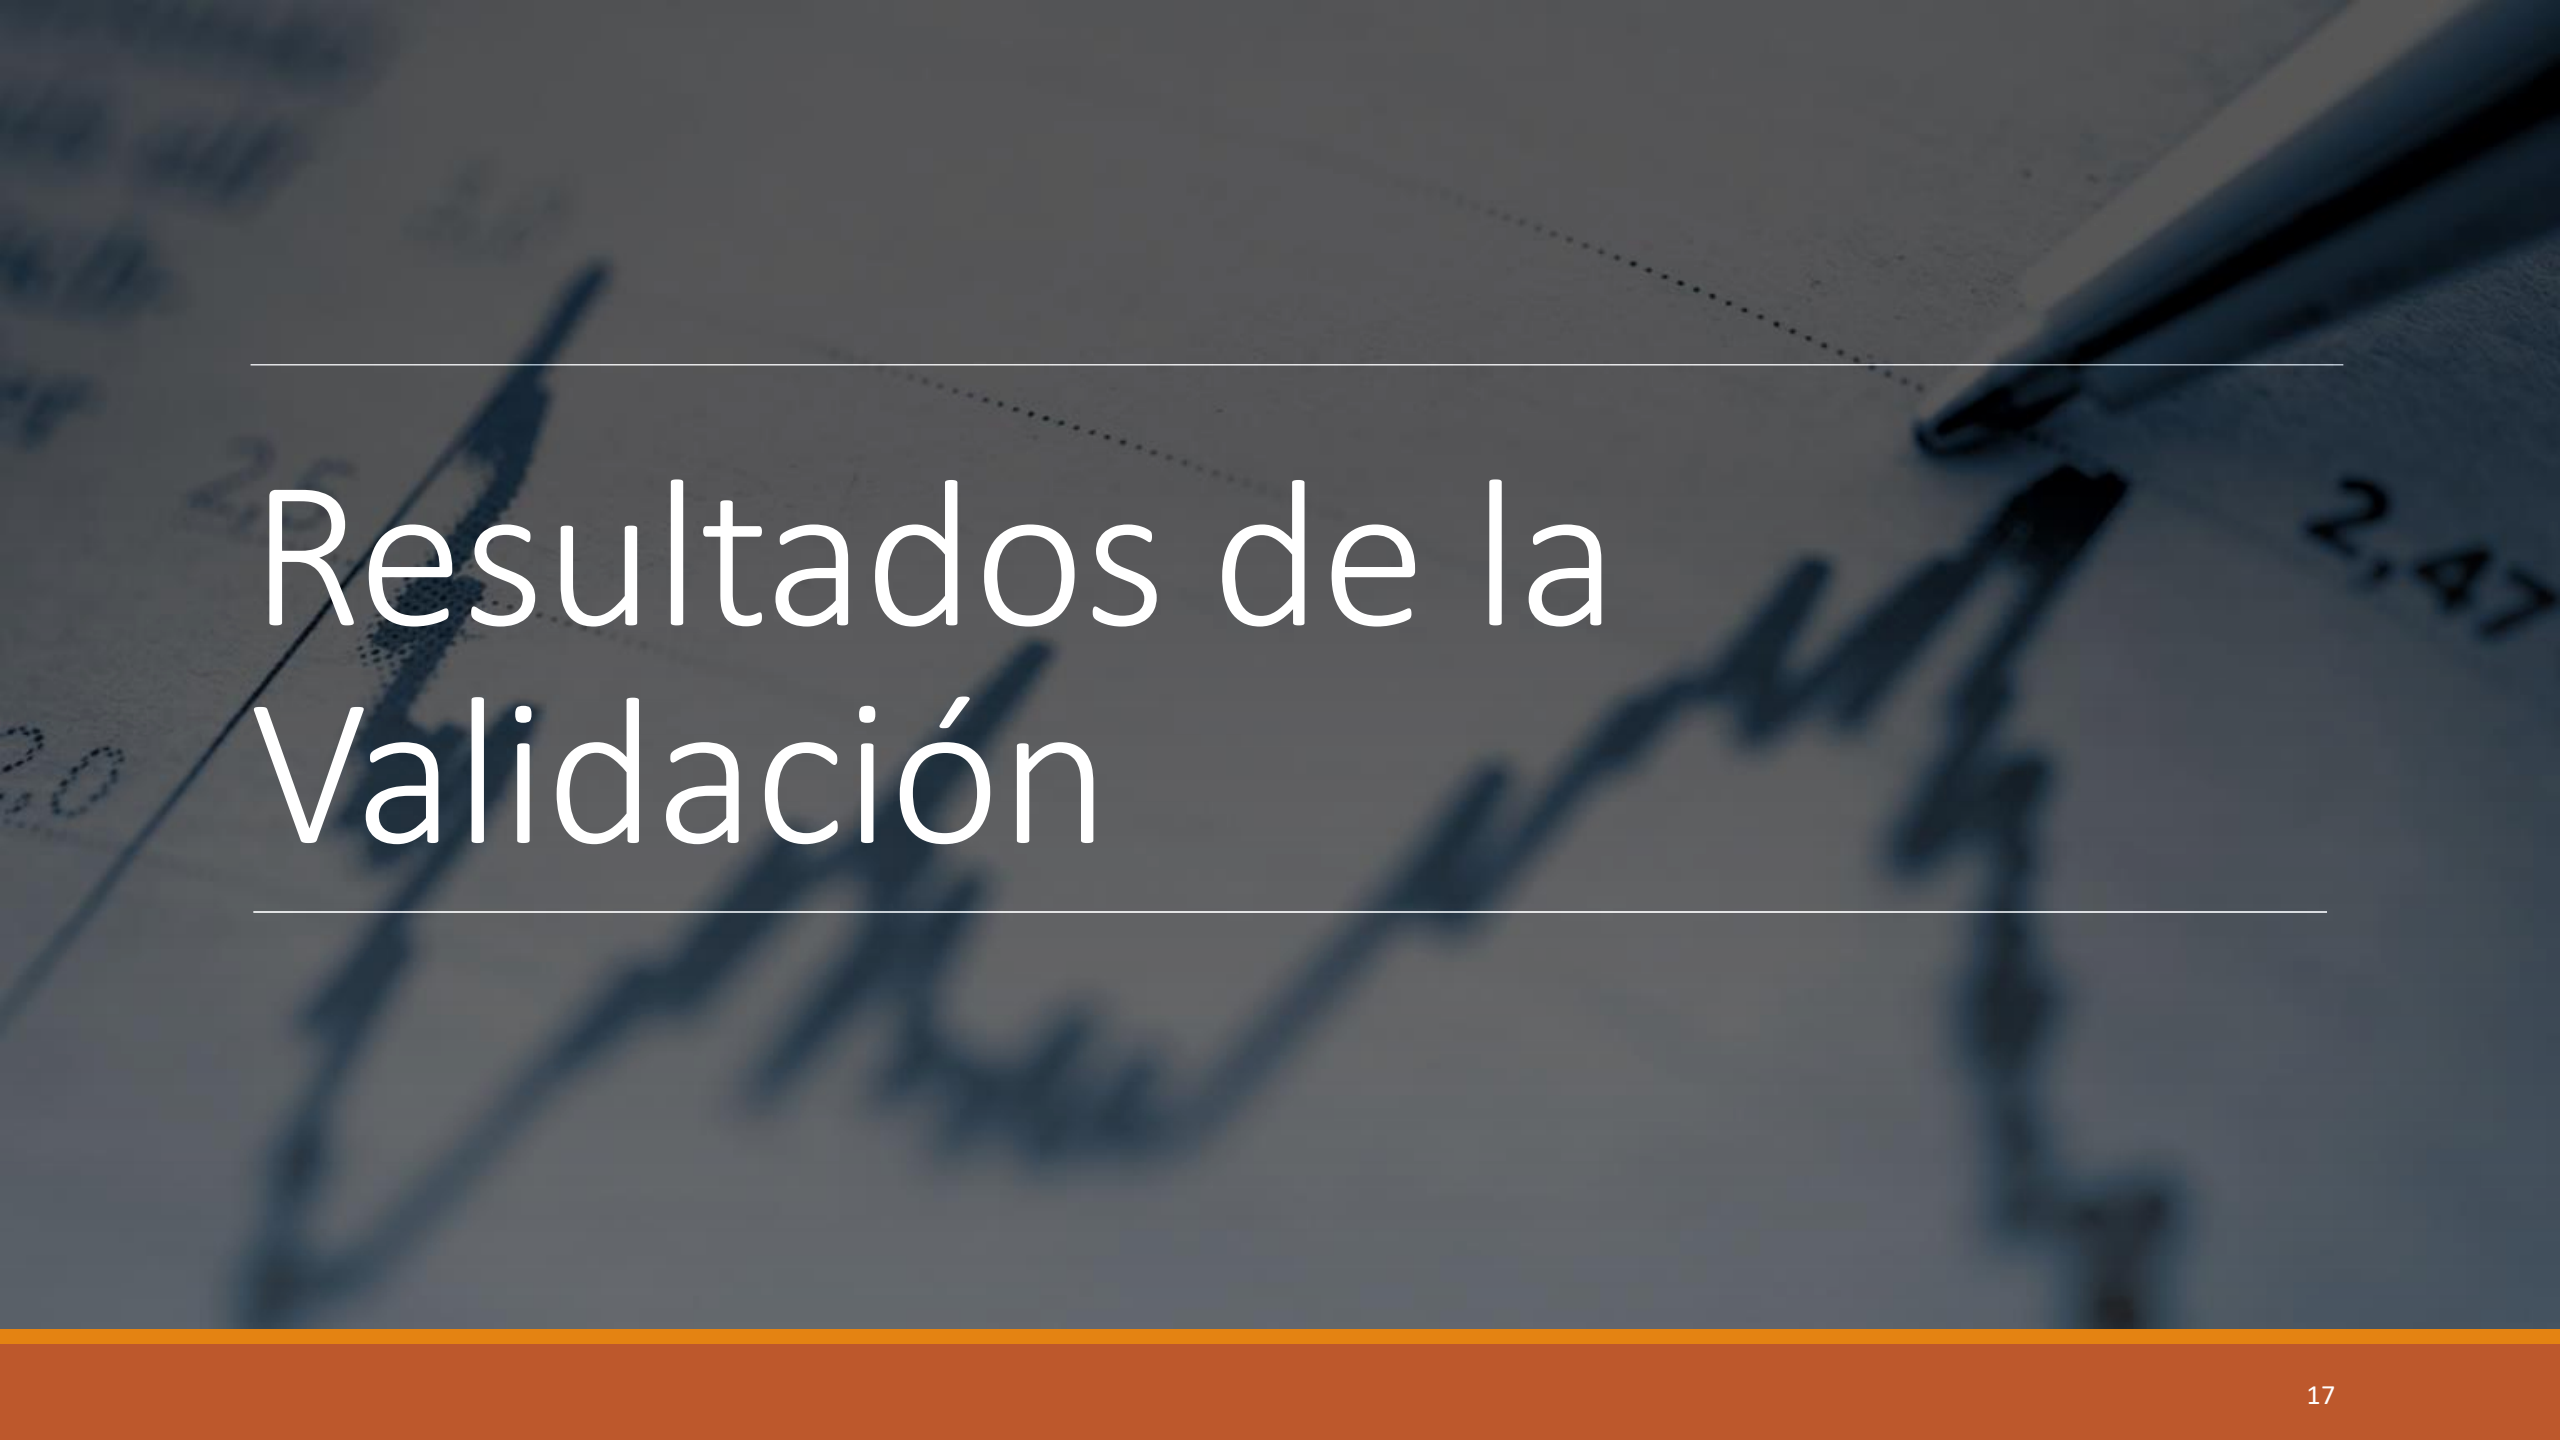


Exposición



Saturación



The background of the slide is a dark, blurred image of a document. A pen is visible in the upper right corner, and a line graph with data points is visible in the lower right corner. The text 'Resultados de la Validación' is centered in the middle of the slide, flanked by two horizontal white lines.

# Resultados de la Validación

# Prueba de validación 1

▪Precisión para detectar objetos en imágenes del dataset KITTI

Solución	Automóviles (%)	Peatones (%)	Ciclistas (%)
Métricas referencia [1]	90	80	90
Yolov8	94	87	96
Detectron2	96	87	94
SSD-NAS	84	74	86

# Resultados prueba de validación 2

■ Precisión para la detección en imágenes en distintos ambientes

Solución	Referencia	Imagen Sencilla (%)	Imagen Moderada (%)	Imagen Compleja (%)	Promedio
YOLOv8	Automóvil	99.63	94.93	84.82	93.13
	Ciclista	94.24	81.26	63.14	74.54
	Peatón	90.02	69.86	61.32	73.73
Detectron2	Automóvil	97.34	94.15	87.13	92.87
	Ciclista	94.95	84.68	72.16	83.93
	Peatón	88.31	79.26	60.87	76.15
SSD NAS	Automóvil	95.90	95.31	81.95	91.05
	Ciclista	85.84	69.64	65.11	73.53
	Peatón	72.65	57.91	51.92	60.83

# Resultados para prueba de validación 3

## ■Velocidad de procesamiento y comunicación

Solución	Escenario	Tiempo promedio (ms)	Tiempo máximo en los experimentos (ms)	Método de Comunicación	¿Es una solución viable?
1. (YOLOv8)	1	96.1353	131.2845	UDP	No
	2	89.2329	121.9422		
	3	98.5976	131.1523		
1. (YOLOv8)	1	19.4654	32.5150	TCP/IP	Sí
	2	19.6702	26.1049		
	3	15.4049	19.0020		
2. (Detectron2)	1	119.5725	314.6020	TCP/IP	No
	2	118.7578	304.8083		
	3	122.0785	307.8356		
3. (SSD-NAS)	1	7.5770	11.0017	TCP/IP	Sí
	2	7.5616	12.0012		
	3	7.6782	11.0035		

# Resultados para la prueba de validación 4

## ■ Precisión en el rastreo

Solución	Escenario	Fotogramas con objetos conocidos	Fotogramas con objetos detectados	Porcentaje de error (%)	¿El rastreo falla?*
1. (YOLOv8)	1	100	99	1	No
	2	60	60	0	No
	3	150	150	0	No
2. (Detectron2)	1	100	97	3	No
	2	60	58	3.33	No
	3	150	148	1.33	No
3. (SSD-NAS)	1	100	98	2	No
	2	60	55	6.67	Sí
	3	150	147	2	Sí

\*El rastreo falla si en el mismo experimento se le asignan dos o más ID a un único objeto

# Prueba de validación 5

§ Precisión en estimación de distancias

§ < 5% según EURO-NCAP

Solución	Velocidad (km/h)	Porcentaje de error promedio (%)	Valor de error máximo
1. YOLOv8	10	2.0328	4.8585
	25	2.4590	4.8532
	50	2.2664	4.9043
2. Detectron2	10	2.0475	4.4047
	25	1.8244	3.9428
	50	2.5571	4.8483
3. SSD-NAS	10	2.1246	3.9742
	25	2.5126	5.6332
	50	2.9114	5.3478



# Conclusiones

# Conclusiones

---

- Únicamente los prototipos realizados con las arquitecturas de Yolov8 y Detectron2 cumplen con los estándares de precisión tanto general como en distintos entornos.
- De los tres prototipos, los que utilizan Yolov8 y SSD-NAS son capaces de sobrepasar la métrica de 50ms de tiempo de procesamiento
- La comunicación por TCP/IP es eficaz, aumenta el tiempo de procesamiento en un 14.6%
- Se diseñó e implementó un sistema de rastreo compatible con los 3 prototipos, posee error menor al 5% en las soluciones de Yolov8 y Detectron2
- La aproximación de distancias a varias velocidades no excede el 5% de error para los prototipos que utilizan Yolov8 y Detectron2
- Se validaron y compararon las tres propuestas en diferentes métricas, obteniendo un concepto ganador: Yolov8



## Recomendaciones

---

Mayor poder computacional

---

Explorar técnicas de optimización más robustas-modernas (pero a un mayor costo computacional) para mejorar el proceso de entrenamiento

---

Valorar alternativas al método de comunicación para minimizar el impacto en el tiempo de procesamiento

---

Explorar potenciales optimizaciones al modelo actual al hacer un análisis tipo *benchmark* con otros API's como Caffe, o MobileNet, entre otros.

---

# Beneficios Generados a la Empresa

Problema	Actualmente	Beneficio del proyecto
<b>Tiempo de adaptación de nuevos empleados a las aplicaciones de ADAS</b>	Alrededor de un mes con las capacitaciones existentes.	Se reduce el tiempo de adaptación en un 50%.
<b>Realizar demostraciones de aplicaciones generadas en NICR</b>	Actualmente se realizan entre 0 y 1 demostración de funcionamiento por mes debido a la falta de hardware especializado.	Se puede aumentar el nivel de demostraciones exponencialmente, se asegura mínimo 2 demostraciones de funcionamiento por mes.
<b>Capacidad de desarrollar y validar aplicaciones diseñadas internamente</b>	No hay desarrollo de aplicaciones de ADAS 100% propias de NICR, todas dependen de insumos de empresas ajenas.	Se podrán generar aplicaciones para sistemas ADAS que pertenecen 100% a NICR. Se asegura el desarrollo de mínimo una aplicación por año.
<b>Tiempo de desarrollo para ECU propias de NICR</b>	Se estimó un periodo de 2 años para confeccionar ECU propias de NICR.	Se ahorra hasta un 50% del tiempo de desarrollo considerado para ECU especializadas en frenado automático de emergencia, además de generar una base para cualquier otro tipo de aplicación ADAS que se desee.

# Referencias

---

[1] Fritsch, J., Kuehnl, T., & Geiger, A. (2013, October). A new performance measure and evaluation benchmark for road detection algorithms. In Proceedings of the 2013 IEEE 16th International Conference on Intelligent Transportation Systems (pp. 1963-1968). IEEE.

[2] A. Geiger, P. Lenz, and R. Urtasun, "Are we ready for Autonomous Driving? The KITTI Vision Benchmark Suite," in Conference on Computer Vision and Pattern Recognition (CVPR), 2012.